Agresiones en la página de Instagram de Noticias Uno

Sofía Cuartas García Simón Cuartas Rendón Julián Alejandro Úsuga Ortiz Deivid Zhang Figueroa

Febrero de 2022

Motivación y contexto

Durante la última década se ha visto un aumento vertiginoso en la cantidad de usuarios que tienen cuentas en las diferentes redes sociales disponibles en el mercado, permitiendo a las personas interactuar de nuevas maneras mediante estos espacios virtuales, en los cuales les resulta posible compartir momentos de sus vidas mediante fotografías o videos, así como encontrarse con otros usuarios para discutir puntos de vista sobre algún tema y compartir noticias o contenidos de su interés.

No obstante, uno de los grandes problemas asociados a las redes sociales es la proliferación de agresiones y contenido de odio desde las más diversas fuentes, como lo pueden ser las noticias falsas, interacciones con usuarios con ideologías diferentes y comentarios a influencers (personas destacadas en las redes sociales) que no son de su agrado, entre otras.

Es por ello que nos motivamos a estudiar la cantidad total de comentarios con adjetivos peyorativos, emojis o cualquier otra representación o símbolo que evidencien de forma explícita la intención de agredir a una persona, grupo de personas, empresa, región geográfica o institución pública o privada, entre otras, que ocurren en la sección de comentarios de las publicaciones de Instagram del medio de comunicación Noticias Uno de Colombia. Pero además, se va a estudiar el promedio de comentarios peyorativos por publicación. Adicionalmente, se va a estimar la proporción de comentarios agresivos con el objetivo de mejorar las estimaciones (que son aquellas que carecen de un nombre real o una foto con una persona en ella).

Parámetros a estimar

- Total de comentarios peyorativos en la sección de comentarios de las publicaciones de Instagram del medio de comunicación Noticias Uno de Colombia.
- Promedio de comentarios que se consideran negativos en la sección de comentarios de las publicaciones de Instagram del medio de comunicación Noticias Uno de Colombia.

Aspectos importantes

- **Elemento.** Se considera como elemento a cada uno de los comentarios en las publicaciones de Instagram realizadas por el medio de comunicación radial Noticias Uno de Colombia.
- **Población.** La población está dada por la totalidad de comentarios realizados en las publicaciones de Instagram realizadas por el medio de comunicación radial Noticias Uno de Colombia.

- Unidad de muestreo. Para lograr la estimación de los parámetros de interés, se realizará el estudio considerando como unidad de muestreo a cada uno de los comentarios de las publicaciones de Instagram realizadas por el medio de comunicación radial Noticias Uno de Colombia, que con corte a las 4:00 p.m. del viernes 10 de diciembre de 2021 totalizaron 2,290 publicaciones. Se debe tener en cuenta, además, que para poder listar todas estas publicaciones se usó XXXX, el cual es una extensión de Chrome que se encarga de enlistar de forma automática todas las publicaciones de cualquier página de Instagram junto su enlace y la fecha de publicación de cada publicación, además de asignarle un número, el cual usamos como denominación para una de las publicaciones. Luego, para cada publicación, se tiene que esta exhibe de forma pública el número de comentarios que hay en esta y luego se los enlista en orden de aparición.
- Tipo de muestreo. Para abordar este trabajo se va a emplear el muestreo por conglomerados, para lo cual se toman los índices o ID de cada uno de los elementos muestrales, esto es, las fotos publicadas en la página de Instagram de Noticias Uno y se les organiza aleatoriamente para proseguir con una agrupación en grupos de quince publicaciones para poder construir los conglomerados, que serán quince en total, y a continuación se seleccionan de forma aleatoria veinte conglomerados para poder proceder con el muestreo. Todo lo anterior se realiza con ayuda de R.

Levantamiento de la información.

Para poder realizar el levantamiento de la información usando muestreo por conglomerados se apeló a una herramienta llamada *DownAlbum*, que se encarga de enumerar cada una de las publicaciones de la página de *Instagram* de *Noticias Uno*, incluyendo el enlace que dirige a cada publicación, la fecha en la que fue subida a la red social y un índice, dándole el primer número a la publicación más reciente al momento de generar el listado, y el último a la primera publicación compartida por Noticias Uno en *Instagram* (la mas antigua). De esta forma, teniendo en cuenta que se consideraron todas las publicaciones que se hicieron hasta el sábado 11 de diciembre de 2021 a las 16:00 (4:00 p.m. GMT -5, es decir, hora de Bogotá), se tiene que el tamaño de la población, osea, el número total de publicaciones en Instagram de Noticias Uno hasta dicha fecha es de 2,290 y se procede con la construcción de los conglomerados como se explicó antes

Con lo anterior presente, se generan con R cuarenta números aleatorios para determinar cuáles van a ser los conglomerados a censar para recoger la información necesaria, los cuales se observan en la siguiente tabla

Para su levantamiento, entonces, cada uno de los cuatro integrantes asumió la recogida de datos de cinco conglomerados. Ahora bien, para el registro de los datos se creó un formulario de Microsoft Forums, el cual puede ser visto dando clic aquí. A continuación se muestran y se justifican cada uno de los elementos de este formulario.

- Encuestador. Registra cuál es la persona que está llenando la información.
- Enlace. Dirección web de la publicación.
- ID. Número de la publicación en el marco muestral.
- Conglomerado. ID del conglomerado asociado a la publicación censada.
- Fecha de publicación. Fecha en la que fue subida la publicación a Instagram.
- Número de comentarios. Cantidad total de comentarios.
- Número de comentarios con mensajes peyorativos. Cantidad de comentarios en la publicación que tenían mensajes peyorativos, agresivos o violentos, entre otros.
- Tema. Temática con la que se asocia la publicación. Para esta pregunta existen cuatro posibilidades:
- Política nacional.
- Deportes.
- Entretenimiento.
- Otros.

Y una vez recogidos los datos para las cuarenta publicaciones asignadas aleatoriamente por R, se genera automáticamente un cuadro en Excel con las respuestas, que puede ser visualizado haciendo clic aquí.

Evidencia fotográfica

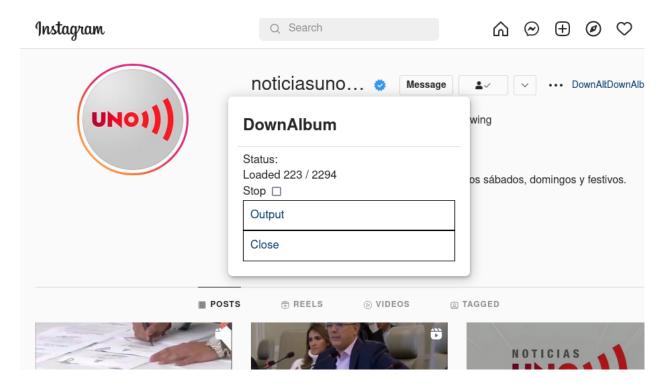


Figure 1: Recolección de publicaciones con la herramienta DownAlbum.

Estudio piloto

Bla, bla, bla

Como se manifestó previamente, en este estudio se están considerando N=153, cada uno de M=15 unidades básicas. Así, se tiene que el número de unidades elementales en la población, es decir, el número publicaciones total a considerar es $M_0=NM=2295$, que como se nota, son cinco unidades elementales más de las que realmente fueron consideras, esto porque se aleatorizaron los conglomerados con cinco unidades elementales imaginarias extras para poder asegurar que todos tuvieran tamaño uno. Ahora bien, para este estudio piloto se están considerando n=20 conglomerados diferentes, seleccionados de manera aleatoria con ayuda de R, obteniendo que los que deben ser considerados son los siguientes:

Insertar lista de conglomerados a estudiar (db conglomerados)

Con esto, se va a considerar a μ_c como la media de comentarios peyorativos por conglomerados, μ la media de comentarios peyorativos en toda la población, es decir, en todas las publicaciones de *Noticias Uno* consideradas hasta la fecha de corte y τ el total. Además, sea y_{ij} el número de comentarios peyorativos registrados en la i-ésimo publicación del j-ésimo conglomerado. Se sabe que los parámetros anteriores pueden ser calculados como sigue:

$$\tau = \sum_{i=1}^{N} \tau_i = \sum_{i} \sum_{j} y_{ij}$$
$$\mu_c = \frac{\tau}{N}$$
$$\mu = \frac{\tau}{NM} = \frac{\tau}{M_0}$$

	dio sobre la cantidad de comentarios violentos, agresivos o peyorativos en las cajas de comentarios de las caciones de la W Radio
* Re	quired
1. E	ncuestador *
	Deivid Zhang
	Julián Úsuga
	Sofia Cuartas Simón Cuartas
) Sillion Cualida
2. E	nlace de la publicación de instagram *
	Enter your answer
3. N	úmero de la publicación en el marco muestral *
L	Enter your answer
4 N	úmero del conglomerado que acoge a la publicación *
	grese solo un número
	Enter your answer
э. г Г	echa de la publicación * Please input date (M/d/yyyy)
	Friedse input date (wirdryyyy)
	Enter your answer úmero de publicaciones con mensajes peyorativos, agresivos o violentos, entre otros. * umbién se deben contar aquellos mensajes que incluyan siglas, emoticones o emojis que se empleen con la
in	tención de ofender a alguien. Introduzca únicamente un número. Enter your answer
p Ta in	úmero de publicaciones con mensajes peyorativos, agresivos o violentos, entre otros hechos or cuentas anónimas.* untibén se deben contar aquellos mensajes que incluyan siglas, emoticones o emojis que se empleen con la tención de ofender a alguien, y se entiende por cuenta anónima aquella que no puede ser relacionada con alguna resona, empresa o institución real, isno que se evidentemente manejada por una persona que se aprovecha del nonimato en las redes sociales. Introduzca únicamente un número.
	Enter your answer
a	Con qué tema puede ser asociada la publicación? *
9. ¿	Con qué tema puede ser asociada la publicación? *) Política nacional
9. ¿	Politica nacional Politica internacional
9. ¿	Politica nacional Politica internacional Deportes
9. ¿	Politica nacional Politica internacional Deportes Entretenimiento
9. ¿	Politica nacional Politica internacional Deportes Entretenimiento Publicidad
9. ¿	Politica nacional Politica internacional Deportes Entretenimiento
9. ¿	Politica nacional Politica internacional Deportes Entretenimiento Publicidad
9. ¿	Politica nacional Politica internacional Deportes Entretenimiento Publicidad Otro

Figure 2: Herramienta usada para poder recopilar los datos facilmente (Office Forms). $\stackrel{}{4}$

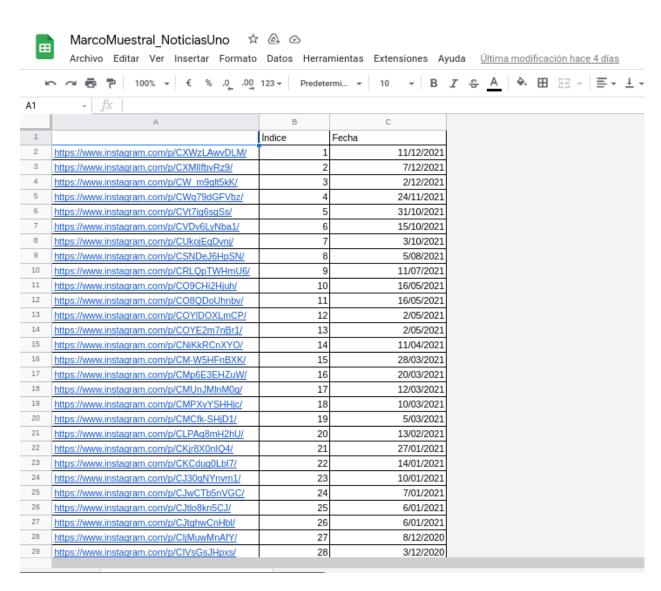


Figure 3: Marco muestral, donde cada publicación representa un conglomerado de comentarios.

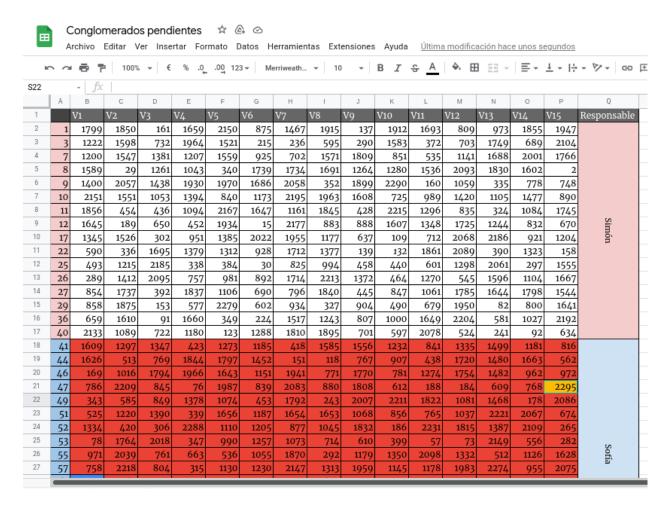


Figure 4: Asignación de las publicaciones y conglomerados a muestrear y progreso de este.

=	-																		Total	13 cambios	^ ~	Mostrar solo versiones con nombre	
37	76	1453	759	1718	780	359	2110	1821	1543	2132	55	1843	1560	1386	1774	1616						Deivid Zhang Figueroa	
38	80	1945	924	707	829	1123	1989	565	2202	784	412	477	927	554	310	172						Julián Alejandro Úsuga Ortiz	
39	81	872	1107	1176	120	1006	1613	1668	1858	1886	2030	713	1234	373	1953	2285							
40	82	1417	1090	860	439	1887	63	356	1707	405	58	1462	1012	401	653	1793						▶ 30 de enero, 15:20	
41	84	1562	1813	517	197	115	2011	975	1492	791	1992	2107	534	105	2124	24						 Julián Alejandro Úsuga Ortiz Deivid Zhang Figueroa 	
42	87	1519	1456	345	735	1952	421	337	1007	2128	546	1869	941	1913	434	727						Delvid Zhang Figueroa	
43	89	977	204	141	13	721	144	691	711	1303	1973	726	1901	301	1052	503	Julián					▶ 30 de enero. 11:37	
44	90	1570	12	2069	1871	2035	1800	492	1370	9	1259	1528	1322	2102	1360	1191						Julián Alejandro Úsuga Ortiz	
45	93	739	1047	844	1302	2017	696	1723	487	316	2008	1247	1397	217	408	830						 Deivid Zhang Figueroa 	
46	97	1743	1965	576	2106	913	170	2207	1601	1476	1849	613	527	206	494	2090							
47	99	245	583	72	906	1242	790	209	2053	1216	2122	1434	1291	1816	2105	251						▶ 30 de enero, 2:45	
48	104	154	2216	37	2070	2159	264	283	1156	459	2253	2277	1131	364	1867	164						Deivid Zhang Figueroa	
49	105	902	607	1545	526	422	74	2015	673	461	287	455	620	1157	448	738				SÁBADO			
50 51	108	1087	2203	1064	2040	256	389	2240	1432	409	514	2278	1077	764	1592	1095							
51	110	2153 1431	750 1670	1504 2099	38 2063	2282 1540	792 1564	2236 2238	1083	2080 1587	1142 2024	2270	1137 1524	498	70 2176	1732 1414						 29 de enero, 23:12 	
53	114	1431	1624	1263	1520	182	1389	1152	802	1101	618	1287 697	489	1317 468	1505	1614			 Sofia Cuartas Garcia Julián Aleiandro Úsuga Ortiz 				
54	116	893	395	232	432	2117	706	93	2073	1935	1017	378	2116	859	261	2014						Julian Alejandro Usuga Urtiz	
55	118	2261	1041	1982	2114	547	742	1990	2241	1199	519	836	1689	1473	1174	414						> 29 de enero. 18:26	
56	119	1801	1491	837	959	171	720	1538	969	488	2066	1909	1054	2062	466	1449						Simón Cuartas Rendón	
57	120	1733	1005	1756	810	1237	1032	2246	2092	1050	167	2050	1218	963	626	240						 Julián Alejandro Úsuga Ortiz Sofia Cuartas Garcia 	
58	121	1444	1828	1470	84	676	942	1188	1415	575	2291	496	354	273	1632	288						Alejandro Aristizabal Londono	
59	123	801	1694	25	1306	1044	1224	1802	313	2263	728	2266	1919	1672	1058	2293						Deivid Zhang Figueroa	
60	124	475	518	2002	1388	1615	386	639	754	1769	1685	1851	1490	255	1894	2258	Deivid						
61	128	133	903	1503	1206	502	662	1269	744	1864	1450	1539	249	85	481	1308						▶ 29 de enero, 8:26	
62	129	1999	159	511	375	2006	308	1281	787	1772	682	331	1552	677	596	716						Simón Cuartas Rendón	
63	132	776	1361	69	40	1956	49	1117	2286	1315	1086	1478	1889	2054	2003	56						29 de enero, 8:05	
64	137	130	838	867	60	1859	1065	1621	785	2226	923	1030	1762	1376	1823	1120						Simón Cuartas Rendón	
65	140	2046	124	945	473	1121	66	533	623	1366	1171	2284	1458	1726	991	456							

Figure 5: Progreso y evidencia de muestreo realizado por cada uno de los integrantes.

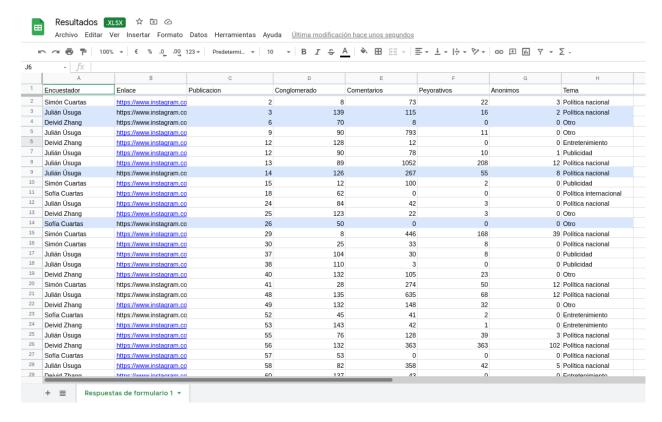


Figure 6: Resultados del muestreo, extraidos a formato EXCEL usando Office Forms.

Así, vale la pena comenzar observando el resultado obtenido en cada uno de los conglomerados en la siguiente tabla:

Table 1: Resultados en los conglomerados del estudio piloto

Conglomerado	Comentarios	Peyorativos	Anonimo
107	254	44	0
113	226	16	0
125	75	14	0
126	727	108	18
135	1722	230	32
136	53	3	1
139	324	56	6
153	143	20	1
19	242	39	2
2	210	32	8
23	180	5	0
28	590	88	20
34	159	26	7
35	87	18	1
39	481	65	8
45	93	9	0
50	128	18	6
60	95	15	0
70	84	7	0

Conglomerado	Comentarios	Peyorativos	Anonimo
91	90	10	0

Definido lo anterior, se puede comenzar estimando la media poblacional por conglomerado μ_c mediante la media muestral por conglomerado $\hat{\mu}_c$, el cual, teniendo en cuenta que los conglomerados tienen igual tamaño, puede ser calculada como sigue:

$$\hat{\mu}_c = \frac{1}{n} \sum_{i=1}^n \tau_i = \bar{y}_c$$

Así que al emplear la información de la tabla uno, se tiene que la media muestral por conglomerado es:

$$\hat{\mu}_c = \frac{4+16+\ldots+7+10}{20} = \frac{823}{20} = 41.15$$

mo

Lo que quiere decir que en cada conglomerado hay un promedio de 41.15 comentarios peyorativos. Y con esto se puede estimar la cantidad promedio de comentarios peyorativos por unidad elemental como sigue:

$$\hat{\mu} = \frac{\hat{\mu}_c}{M} = 2.7433$$

Es decir, existe un promedio de 2.74 comentarios peyorativos, agresivos o irrespetuosos en cada publicación de *Instagram* de *Noticias Uno*. Además, el total de comentarios peyorativos puede ser estimado como sigue:

$$\hat{\tau}_c = N\hat{\mu}_c = 2295 \times 41.15 \approx 6295.95$$

De manera que se estima que se han dejado un total de 6296 comentarios peyorativos en todas las publicaciones de *Instagram* de *Noticias Uno* que habían si subidas a la red social hasta el once de diciembre de 2021.

Ahora bien, con el objetivo de determinar cuál es el número de conglomerados que deben ser estudiados en el muestreo final, es necesario obtener la varianza estimada de los estimadores expuestos previamente, lo cual se consigue con las siguientes ecuaciones:

$$\widehat{Var}[\widehat{\tau}_c] = \frac{N(N-n)}{N} \sum_{i=1}^n \frac{(\tau_i - \widehat{\mu}_c)^2}{n-1}$$

$$\widehat{Var}[\widehat{\mu}] = \frac{1}{M_0^2} \widehat{Var}[\widehat{\tau}_c]$$

Y al realizar los respectivos cálculos se tiene que los estimadores de dichas varianzas son:

$$\widehat{Var}[\widehat{\tau}_c] = 2835394.8525$$

$$\widehat{Var}[\widehat{\mu}] = 0.5383$$

Y con estos cálculos se tienen la mayoría de elementos necesarios para poder determinar el número de conglomerados que deben ser finalmente considerados.

Tamaño de muestra para la media poblacional

Para calcular el número de conglomerados n_{μ} necesarios para estimar con la muestra a la media de comentarios peyorativos en todas las publicaciones es necesario emplear la siguiente ecuación:

$$n = \frac{n_0}{1 + \frac{n_0}{N}}, \qquad n_0 = \frac{Z_{\alpha/2}^2 S_{con}^2}{B_u^2 M^2}$$

Así, es necesario calcular el valor de S_{con}^2 , el cual puede ser calculado como sigue:

$$S_{con}^{2} = \sum_{i=1}^{n} \frac{(\tau_{i} - \hat{\mu}_{c})^{2}}{n-1}$$

Para el cual, al realizar los cálculos con R, se obtiene que $S_{con}^2=2786.7658$. Además, considerando que se va a emplear un nivel de confianza del 90 % ($\alpha=0.10$) (con lo que $Z_{0.05/2}=1.6449$) y un límite en el error de la estimación relativo del 10%, es decir, $\epsilon=0.15$, de manera que el límite en el error de estimación B_{μ} es: $B_{\mu}=0.10\times 2.7433=0.4115$. Así, se tiene que el número de conglomerados a muestrear si estos fuesen infinitos es:

De manera que, al realizar la corrección por población finita y realizar las cuentas, se tiene que el número de conglomerados a muestrear es 87

Tamaño de muestra para el total

Para encontrar el tamaño de muestra necesario para estimar el total poblacional es necesario emplear la siguiente ecuación:

$$n = \frac{NS_{con}^2}{ND + S_{con}^2}, \quad D = \frac{B_\tau^2}{Z_{\alpha/2}^2 N^2}$$

De manera que para poder emplear esta ecuación es necesario comenzar encontrando el límite en el error de estimación, que, considerando que este está dado por $B_{\tau} = \epsilon \times \hat{\tau}_c$, de manera que se obtiene que $B_{\tau} = 944.3925$. Luego, realizando las cuentas indicadas por las dos ecuaciones anteriores se tiene que:

$$D = 14.0821, \quad n_{\tau} \approx 86.2876$$

Y como se ve el resultado es el mismo que para el tamaño de la muestra de la media poblacional, es decir, que se deben muestrear un total de 87 conglomerados.

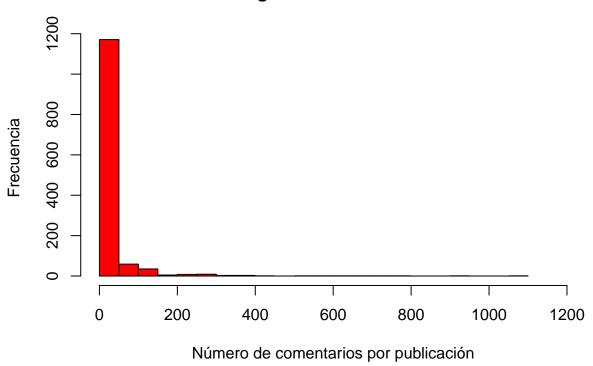
Tabla resumen de los datos obtenidos en la encuesta.

Variable comentarios.

Esta variable contiene el números total de comentarios para cada publicación muestreada, unos estadísticos de resumen son los siguientes:

Número de comentarios por publicación						
Minimo	0					
Primer Cuantil (Q1)	1					
Mediana	2					
Tercer cuantil (Q3)	12					
Máximo	1052					
Moda	0					

Histograma de comentarios



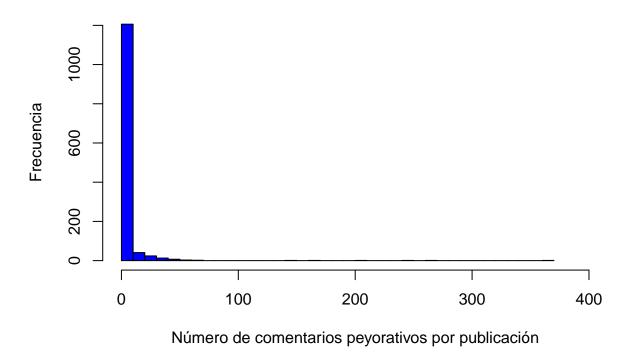
vemos que el número de comentarios que más se repite es cero con una frecuencia de 301, además como se puede ver en el gráfico de barra el número de comentarios varía mucho, y es evidente que un número de comentarios más pequeño es lo más frecuente para una publicación.

Variable peyorativos.

Esta variable contiene el número de comentarios peyorativos de cada publicación; a continuación una tabla con estadísticos de resumen y el respectivo diagrama de barras

Número de comentarios peyorativos por publicación						
Minimo	0					
Primer Cuantil (Q1)	0					
Mediana	0					
Tercer cuantil (Q3)	1					
Máximo	363					
Moda	0					

Histograma de comentarios peyorativos

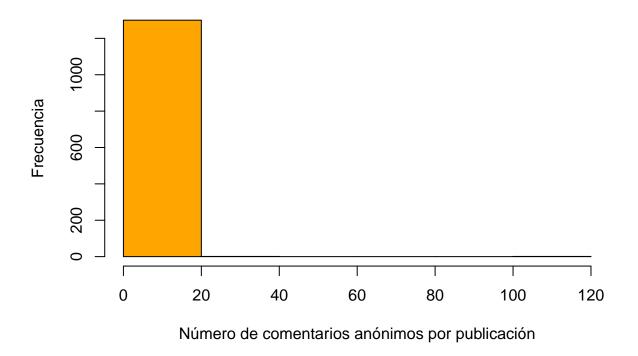


Sabemos que el numero que mas se repite es cero con una frecuencia de 841, Nuevamente se observa que los valores que puede alcanzar esta variable varía bastante y que aún sigue siendo más frecuente un número más pequeño de comentarios peyorativos, lo que cambia esta vez es que la frecuencia de estos comentarios es mucho menos en comparación con la frecuencia de comentarios totales.

Variable anonimos.

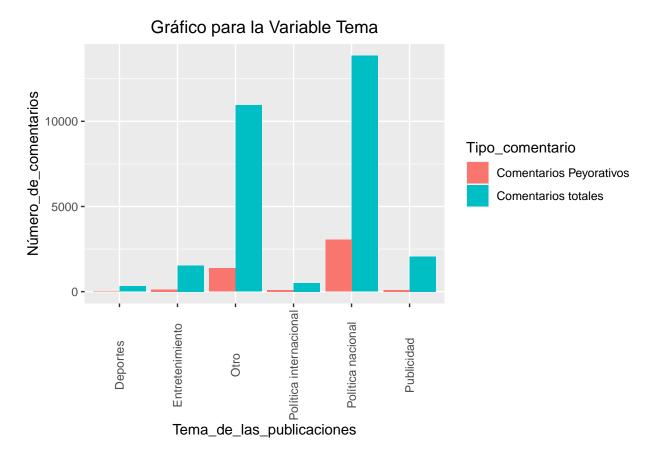
Número de comentarios anonimos por publicación						
Minimo	0					
Primer Cuantil (Q1)	0					
Mediana	0					
Tercer cuantil (Q3)	0					
Máximo	102					
Moda	0					

Histograma de comentarios anónimos



Es evidente que el número de comentarios para esta variable se reduce en gran medida, y por lo que nos muestra los estadísticos de resumen parece ser que no suele haber comentarios realizados por cuentas anónimas.

Variable Tema.



En la anterior gráfica de barras se puede evidenciar que las publicaciones que están asociadas a política nacional son las que reciben más comentarios en general y comentarios peyorativos, le siguen las publicaciones relacionadas con otro tipo de temas, además resalta que las publicaciones relacionadas con deporte son las que menos comentarios reciben y parece ser que los comentarios peyorativos que contienen son mínimos.

9B

Se halla los estimadores

Primeramente agrupamos por conglomerado y hallamos los parámetros de interés que son el total y la media. La media estimada $\hat{\mu}_c$ de comentarios peyorativos por conglomerado está dado por:

[1] 53.89773

Es decir, en promedio hay 54 comentarios peyorativos en cada conglomerado.

Ahora, se halla la media estimada de comentarios peyorativos por publicación $\hat{\mu}$, la cual está dada por:

[1] 3.593182

Es decir, en promedio hay 4 comentarios peyorativos en cada publicación.

Para el total estimado de comentarios peyorativos para los 153 conglomerados está dado por:

 $\hat{\tau}_c = 153 * \hat{\mu}_c = 153 * 53.89773 = 8246.353$. Es decir, hay 8247 comentarios peyorativos en total.

Teniendo estos valores, se halla los intervalos de confianza al 95% para los parámetros de interés μ y τ .

Primeramente, se halla la varianza estimada de $\hat{\tau}_c$ y $\hat{\mu}_c$, y con esta se hallará el error estándar estimado para estos estimadores:

[1] 776.964

El error estándar estimado de $\hat{\tau}_c = 776.964$.

[1] 0.3392856

El error estándar estimado de $\hat{\mu} = 0.3392856$.

Intervalo de confianza al 95% para tau: 6702.053 9790.653

Intervalo de confianza al 95% para mu: 2.918815 4.267549

Luego con un nivel de confianza de 95%, el número total τ de comentarios peyorativos que hay en las 2290 publicaciones se encuentra entre 6703 comentarios y 9791 comentarios, y la cantidad media μ de comentarios peyorativos por publicación se encuentra entre 3 comentarios y 5 comentarios.

Por último, se halla el B usando 88 conglomerados para comprobar si este mejoró.

Primeramente, reemplazando los respectivos valores de la fórmula:

$$n = \frac{n_0}{1 + \frac{n_0}{N}} = 88 = \frac{n_0}{1 + \frac{n_0}{153}} \Longrightarrow n_0 = \frac{13464}{65}$$

Luego, despejando la fórmula siguiente:

$$n_0 = \frac{z^2 S_{con}^2}{B^2 M^2}$$

se tiene que,

$$B = \sqrt{\frac{z^2 S_{con}^2}{n_0 M^2}}$$

Reemplazando los valores obtenidos se tiene que,

$$B = \sqrt{\frac{1.96^2 * 5341.702}{\frac{13464}{65} * 2290^2}}$$

Luego, B=0.0043464, y como podemos evidenciar esta disminuyó, lo que quiere decir que nuestro I.C es más preciso.